

SUNEXT OCR V2 – BÁO CÁO PHÂN TÍCH

Báo Cáo Accuracy OCR 50 File Gần Nhất


Phân tích chất lượng nhận dạng ký tự quang học (OCR) cho 50 tài liệu BCTC PDF gần nhất trên hệ thống SUNEXT OCR v2. Đánh giá dựa trên các chỉ số: tỷ lệ thành công, vn%, loại PDF và phân tích theo doanh nghiệp.

🕒 Ngày báo cáo: 29/06/2026 – 15:50 ICT 🔗 Nguồn: ocr.demo.sunext.vn/results 📁 50 tài liệu BCTC được phân tích


Tổng Quan Kết Quả



Biểu Đồ Phân Tích



Phân Tích Theo Doanh Nghiệp



Nhận Xét & Phân Tích Chi Tiết

 **Điểm Nổi Bật**

 **Tỷ lệ thành công 84%** – Mức chấp nhận được cho OCR tài liệu tài chính tiếng Việt có ảnh scan thực tế.

 **Text PDF chất lượng cao nhất:** Nhóm HNM (8 files, vn% 26.22–26.74%) có văn bản nhúng sẵn trong PDF – đây chính là Ground Truth gốc, không cần OCR.

VN

vn% trung bình 25.9% – Ổn định trong khoảng 24–27%, đây là ngưỡng bình thường cho BCTC tiếng Việt (kỳ vọng lý thuyết ~25–28%).

 **Nhóm BNA tốt nhất:** 19/19 files thành công (100%), vn% ổn định 25.05–26.25%. Bộ tài liệu chất lượng scan tốt.

 **vn% thấp nhất (thành công): 23.90%** – SLS_BCTC_Q1_2017.pdf. Vẫn trong ngưỡng pass nhưng cần theo dõi nếu tiếp tục giảm.

 **Phân Tích 8 File Thất Bại**

FAIL #01 – SLS

SLS_BCTC_Q4_scan.pdf
vn% = 0.04% (cực thấp) · diacritic fidelity too low · 22 trang, 2.789 dòng · File scan bị mờ hoặc OCR không nhận dạng được dấu tiếng Việt

FAIL #41 – SAF

SAF_BCTC_Q1_2016.pdf
Partial failure · Upload error · Xử lý bị gián đoạn không hoàn thành

FAIL #44–49 – HHC (6 FILES)

HHC_BCTC_Q3/Q2/Q1_2016, nam_2015, ban_nien_2016
Toàn bộ nhóm HHC thất bại · Scan chất lượng thấp hoặc font encoding không chuẩn Unicode · Diacritic fidelity không đạt ngưỡng tối thiểu

 **Nguyên Nhân Gốc Rễ**

· **Diacritic fidelity thấp:** Ký tự có dấu (ă→a, ê→e, ô→o) bị lẫn



vn% cao nhất: 27.37% –
HNH_BCTC_kiem_toan_2016.pdf (Scan
PDF). Ảnh scan chất lượng tốt, OCR nhận
dạng dấu tiếng Việt xuất sắc.

- **Chất lượng scan kém:** DPI thấp, ảnh mờ, nghiêng
lệch
- **Font encoding:** PDF dùng font không chuẩn, text
extraction lỗi



Kết Luận & Đề Xuất Cải Thiện

Kết Luận Tổng Thể

- Hệ thống SUNEXT OCR v2 đạt tỷ lệ thành công 84% (42/50 files)**, đây là mức chấp nhận được cho bài toán OCR tài liệu tài chính tiếng Việt dạng scan thực tế. Phần lớn thất bại tập trung ở nhóm HHC (6/8 failures) – cho thấy đây là vấn đề đặc thù của nguồn tài liệu chứ không phải lỗi hệ thống.
- Chỉ số vn% là proxy chất lượng OCR hiệu quả:** Ngưỡng an toàn là $vn\% \geq 22\%$. Files thành công duy trì vn% từ 23.9%–27.4%. Hệ thống đã có cơ chế tự động reject khi $vn\% <$ ngưỡng (SLS Q4 = 0.04% bị từ chối đúng). Tuy nhiên, cần bổ sung thêm CER/WER để đo độ chính xác từng ký tự/từ so với Ground Truth.
- Text PDF cho kết quả tốt nhất:** Nhóm HNM (8 files, 100% thành công, vn% avg 26.5%) dùng PDF có văn bản nhúng sẵn – đây là Ground Truth gốc không cần qua OCR pipeline. Nên ưu tiên sử dụng file PDF gốc (không scan) khi có thể, để loại bỏ sai số OCR hoàn toàn.
- Nhóm BNA là benchmark tốt nhất** với 19 files, 100% thành công, vn% ổn định 25.05–26.25%. Đây là chuẩn tham chiếu về chất lượng scan và quy trình chuẩn bị tài liệu đầu vào.



Đề Xuất Cải Thiện



Bổ sung CER/WER Metric

Thêm module đánh giá Character Error Rate (CER) và Word Error Rate (WER) so với Ground Truth để có benchmark chính xác và tracking theo thời gian.



Tiền Xử Lý Ảnh Scan (HHC)

Tăng DPI lên $\geq 300\text{dpi}$, áp dụng deskew + denoise + contrast enhancement trước khi đưa vào OCR pipeline để xử lý nhóm HHC và các file scan chất lượng thấp.



Tối Ưu Diacritic Recognition

Cải thiện mô hình nhận dạng dấu tiếng Việt – fine-tune trên corpus BCTC để tăng độ chính xác ký tự có dấu từ $\sim 84\%$ lên mục tiêu $\geq 95\%$.



Phân Loại PDF Tự Động

Cải thiện pipeline phân loại text/scan/mixed PDF để route đúng engine xử lý, giảm thời gian OCR và tăng độ chính xác cho từng loại tài liệu.